

Trabajo N.3

HUERTAS, ANTHONY^{1,*}

¹Maestría en Estadística, Escuela de Posgrado, Pontificia Universidad Católica del Perú, Lima, Perú

*Cod: 20173728

Compiled November 14, 2018

Profesora: Zaida Quiroz

1. BASE DE DATOS IRIS - CÓDIGO: IRIS.R

En primera instancia se necesita instalar el paquete INLA, de la forma que se indica en <http://www.r-inla.org/download>

Listing 1. Paquete INLA

```
1 install.packages("INLA", repos=c(getOption("repos"),
2                               INLA="https://inla.r-inla-download.org/R/stable"), dep=TRUE)
3 inla.upgrade(testing=TRUE) # Actualizacion del paquete a su version mas reciente
4
5 library(INLA) # Cargar el paquete
```

En un modelo Gaussiano latente, sobre los datos observados $\mathbf{y} = (y_1, \dots, y_n)$, se tiene que cada y_i se rige bajo una distribución en función de un parámetro ϕ_i , la cual cumple con

$$g(\phi_i) = \beta_0 + \sum_{j=1}^m \beta_j x_{ij} + \sum_{k=1}^p f_k(z_{ik}) \quad (S1)$$

donde $g(\cdot)$ representa la funcion link, $\mathbf{x}_i = (x_{i1}, \dots, x_{im})$ y $\mathbf{z}_i = (z_{i1}, \dots, z_{ip})$ covariables respecto al valor observado y_i , y los f_k funciones sobre los \mathbf{z}_i , las cuales son descritas por

Listing 2. Modelos latentes

```
1 names(inla.models())$latent)
```

```
[1] "linear"      "iid"         "mec"         "meb"         "rgeneric"    "rw1"         "rw2"
[8] "crw2"       "seasonal"    "besag"       "besag2"      "bym"         "bym2"       "besagproper"
[15] "besagproper2" "fgn"        "fgn2"       "ar1"         "ar1c"        "ar"         "ou"
[22] "generic"    "generic0"    "generic1"    "generic2"    "generic3"    "spde"       "spde2"
[29] "spde3"     "iid1d"      "iid2d"      "iid3d"      "iid4d"      "iid5d"     "2diid"
[36] "z"         "rw2d"      "rw2diid"    "slm"        "matern2d"    "copy"      "clinear"
[43] "sigm"      "revsigm"    "log1exp"    "logdist"
```

Fig. S1. Modelos latentes.

De forma similar se pueden observar las distintas distribuciones, descritas en Listing 4 que deseemos modelar para los datos

Listing 3. Distribución de los datos

```
1 names(inla.models())$likelihood)
```

En los códigos posteriores, se trabajará sobre los *datos de Iris* (de Fisher o Anderson), especificados en `?iris` en R, los cuales son datos que contienen a las variables: **Sepal Length** (Longitud de sépalo), **Sepal Width** (Ancho de sépalo), **Petal Length** (Longitud de pétalo) y **Petal Width** (Ancho de pétalo), medidas en centímetros, para una cantidad de 50 flores por cada 3 especies de iris, siendo estas especies: *Iris Setosa*, *Iris Versicolor* y *Iris Virginica*.

Listing 4. base de datos Iris.

```
1 ?iris
2 str(iris)
```

```

[1] "poisson"          "contpoisson"      "qcontpoisson"
[4] "cenpoisson"       "gpoisson"         "binomial"
[7] "testbinomial1"    "pom"              "gamma"
[10] "gammacount"       "qkumar"           "qloglogistic"
[13] "qloglogisticsurv" "beta"             "betabinomial"
[16] "cbinomial"        "nbinomial"        "simplex"
[19] "gaussian"         "normal"           "circularnormal"
[22] "wrappedcauchy"    "iidgamma"         "iidlogitbeta"
[25] "loggammafrailty"  "logistic"         "skewnormal"
[28] "sn"              "sn2"              "gev"
[31] "lognormal"        "lognormalsurv"    "exponential"
[34] "exponentialsurv"  "coxph"            "weibull"
[37] "weibullsurv"      "loglogistic"      "loglogisticsurv"
[40] "weibullcure"      "stochvol"         "stochvolt"
[43] "stochvolnig"      "zeroinflatedpoisson0" "zeroinflatedpoisson1"
[46] "zeroinflatedpoisson2" "zeroinflatedbetabinomial0" "zeroinflatedbetabinomial1"
[49] "zeroinflatedbinomial0" "zeroinflateddbinomial1" "zeroinflateddbinomial2"
[52] "zeroinflatedbinomial2" "zeroinflateddbinomial3" "zeroinflatedbetabinomial2"
[55] "zeroinflatednbinomial0" "zeroinflatednbinomial1" "zeroinflatednbinomial1strata2"
[58] "zeroinflatednbinomial1strata3" "zeroinflatednbinomial2" "t"
[6 names(x)] "rata"             "nmix"             "nmixnb"
[64] "gp"              "logperiodogram"

```

Fig. S2. Distribución de los datos.

```

'data.frame': 150 obs. of 5 variables:
 $ Sepal.Length: num 5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
 $ Sepal.width : num 3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
 $ Petal.Length: num 1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
 $ Petal.width : num 0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
 $ Species : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 1 1 1 1 1 ...

```

Fig. S3. Datos de Iris.

Para este conjunto de datos, se modelará una regresión lineal, donde los datos observados sean representados por `Petal.Length` como en S1, de la forma

$$g(\phi) = \beta_0 + \beta_1 \times \text{Petal.Width} \quad (\text{S2})$$

bajo una distribución **Gaussiana** sobre los datos observados, mediante el siguiente código

Listing 5. Modelo mediante INLA.

```

1 formula <- Petal.Length ~ 1 + Petal.Width
2 output <- inla(formula, family="gaussian", data=iris)
3 summary(output)

```

Teniendose los siguientes resultados

```

Call:
inla(formula = formula, family = "\"gaussian\"", data = iris)

Time used:
  Pre-processing   Running inla Post-processing   Total
        2.7886         1.9413         0.3126         5.0424

Fixed effects:
              mean      sd 0.025quant 0.5quant 0.975quant  mode kld
(Intercept) 1.0836 0.0729    0.9402   1.0836    1.2268 1.0836  0
Petal.width 2.2299 0.0514    2.1289   2.2299    2.3308 2.2299  0

The model has no random effects

Model hyperparameters:
              mean      sd 0.025quant 0.5quant 0.975quant  mode
Precision for the Gaussian observations 4.433 0.511    3.488    4.413    5.49 4.373

Expected number of effective parameters(std dev): 2.004(5e-04)
Number of equivalent replicates : 74.85

Marginal log-Likelihood: -119.59

```

Fig. S4. Resumen del modelo.

Interpretaciones:

- La media de los efectos fijos son: 1.0836 (para β_0) y 2.2299 (para β_1). Así mismo se observa la desviación estándar y quantiles de estos efectos.
- La media de la precisión $\hat{\phi}$ para las observaciones Gaussianas es de 4.433.

Cabe indicar que los resultados del modelo para los efectos e hiperparámetros, se pueden visualizar por separado mediante

Listing 6. Modelo mediante INLA.

```
1 # ----- Efectos fijos
2 output$summary.fixed           # Resumen
3 names(output$marginals.fixed)  # Variables sobre las cuales actúan los efectos
4
5 # ----- Precision para las observaciones
6 output$summary.hyperpar       # Resumen
7 names(output$marginals.hyperpar) # Nombres los hiperparametros
```

cuyas distribuciones respectivas pueden ser obtenidas mediante

Listing 7. Distribución para los efectos β_0, β_1 .

```
1 output$marginals.fixed
2 beta0_post <- output$marginals.fixed$Petal.Width
3 plot(beta0_post, type="l", xlab=expression(beta[0]), ylab=expression(tilde(p)(paste(beta[0], "|", y)
4 )))
5 beta1_post <- output$marginals.fixed$Petal.Width
6 plot(beta1_post, type="l", xlab=expression(beta[1]), ylab=expression(tilde(p)(paste(beta[1], "|", y)
7 )))
```

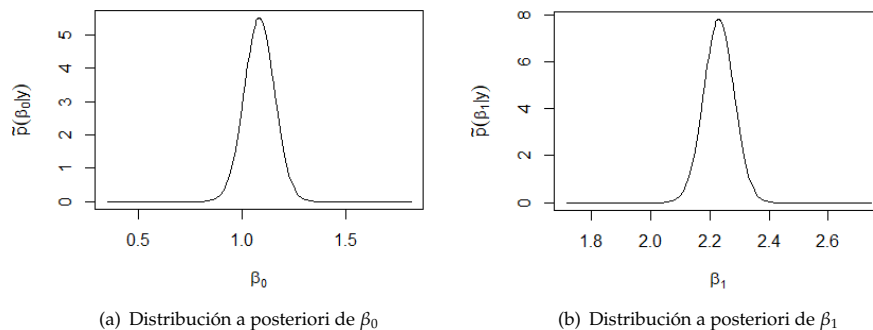


Fig. S5. Distribución de los efectos fijos.

Listing 8. Distribución de la precisión de las observaciones Gaussianas .

```
1 output$marginals.hyperpar
2 prec_post <- output$marginals.hyperpar$'Precision for the Gaussian observations'
3 plot(prec_post, type="l", xlab=expression(phi), ylab=expression(tilde(p)(paste(phi, "|", y))))
```




Fig. S6. Distribución de la precisión de las observaciones Gaussianas.

Pudiéndose además determinar Intervalos de confianza al 95%, en particular del efecto $\beta_1 \mid y$ (distribución a posteriori de β_1) mediante funciones propias del paquete INLA,

Listing 9. IC para $\beta_1 \mid y$.

```
1 IC_beta1 <- data.frame(inla.qmarginal(0.025, beta1_post), inla.qmarginal(0.975, beta1_post))
2 colnames(IC_beta1) <- c("2.5%", "97.5%")
3 rownames(IC_beta1) <- c("beta1")
4 IC_beta1
5
6 # Lo anterior puede resumirse mediante esta funcion:
7 # inla.hpdmarginal(0.95, beta1_post)
```

	2.5%	97.5%
$\beta_1 \mid y$	2.128938	2.330529

Table S1. Intervalo de confianza al 95% para $\beta_1 \mid y$.

Ahora, sabiendo que $\sigma^2 = 1/\hat{\phi}$ (varianza del modelo Gaussiano), entonces

$$Var(\sigma^2) = E[(\sigma^2)^2] - E[\sigma^2]^2 = E[(1/\hat{\phi})^2] - E[\hat{\phi}]^2 \quad (S3)$$

por lo que podemos obtener la desviación estándar, además de la distribución respectiva, de este estimador σ^2 , haciendo uso de la distribución obtenida para $\hat{\phi}$, como se ve a continuación

Listing 10. Distribución para $\sigma^2 \mid y$.

```
1 inla.emarginal(fun=function(x) 1/x, marg=prec_post)
2 m1 <- inla.emarginal(function(x) 1/x, prec_post)
3 m2 <- inla.emarginal(function(x) (1/x)^2, prec_post)
4 sd <- sqrt(m2 - m1^2)
5 sd
6
7 # Grafica
8 plot.default(inla.tmarginal(function(x) 1/x, prec_post),
9               type="l", xlab=expression(sigma^2),
10               ylab=expression(tilde(p)(paste(sigma^2, "|", y))))
```




Fig. S7. Distribución de $\sigma^2 \mid y$. Además, $sd(\sigma^2 \mid y) = 0.02674407$ (desviación estándar).

2. STEP BY STEP - CÓDIGO: INLASTEPBYSTEP.R

Se asume un modelo, bajo $y = (y_1, \dots, y_n)$, de la forma

$$y_i | \mu, \sigma^2 \sim N(\mu, \sigma^2) \quad (S4)$$

con distribuciones a priori:

$$\mu | \sim N(-3, 4^2) \quad (S5)$$

$$\phi = 1/\sigma^2 \sim \text{Gamma}(1.6, 0.4) \quad (S6)$$

El paquete INLA, trabaja de la forma siguiente

$$y_i | \theta, \phi \sim N(\eta_i, \sigma^2) \quad (S7)$$

con $\theta = \eta_i = \mu, \phi = 1/\sigma^2$.

Se presentan datos provenientes de una simulación por parte del modelo en estudio.

Listing 11. Datos

```
1 y <- c(1.2697, 7.7637, 2.2532, 3.4557, 4.1776, 6.4320, -3.6623, 7.7567,
2 5.9032, 7.2671, -2.3447, 8.0160, 3.5013, 2.8495, 0.6467, 3.2371,
3 5.8573, -3.3749, 4.1507, 4.3092, 11.7327, 2.6174, 9.4942, -2.7639,
4 -1.5859, 3.6986, 2.4544, -0.3294, 0.2329, 5.2846)
5 n <- length(y)
6 ybar <- mean(y)
7
8 # Valores que definen las distribuciones a prioris
9 mu0 <- -3
10 sigma2_0 <- 4
11 a <- 1.6
12 b <- 0.4
```

Teniéndose las distribuciones

$$\begin{aligned} \mathbf{y} | \theta, \phi &\sim \prod_{i=1}^n f(y_i | \theta, \phi) \\ \theta &\sim N(-3, 4^2) \\ \phi = 1/\sigma^2 &\sim \text{Gamma}(1.6, 0.4) \\ \theta | \phi, \mathbf{y} &\sim N\left(\frac{\phi \sum_{i=1}^n y_i - 3/4^2}{n\phi + 1/4^2}, \frac{1}{n\phi + 1/4^2}\right) \end{aligned}$$

es de interés determinar la distribución a posteriori de ϕ , representada por

$$\begin{aligned} p(\phi | \mathbf{y}) &\propto \frac{p(\mathbf{y} | \theta, \phi) p(\theta) p(\phi)}{p(\theta | \phi, \mathbf{y})} \\ &= \frac{1}{(2\pi\sigma^2)^{-1/2}} p(\mathbf{y} | \theta, \phi) p(\theta) p(\phi) \end{aligned} \quad (S8)$$

Por tanto, se logra obtener la siguiente representación recursiva

$$p(\phi^{(k+1)} | \mathbf{y}) \propto \frac{1}{(2\pi\sigma^{2(k)})^{-1/2}} p(\theta^{(k)}, 1/\phi^{(k)}) p(\theta^{(k)}) p(\phi^{(k)}) \quad (S9)$$

donde


$$\begin{aligned} \theta^{(k)} &= \frac{\phi^{(k)} \sum_{i=1}^n y_i - 3/4^2}{n\phi^{(k)} + 1/4^2} \\ \sigma^{2(k)} &= \frac{1}{n\phi^{(k)} + 1/4^2} \end{aligned}$$

Listing 12. Distribucion a posteriori de la precisión phi.

```

1 H <- 25
2 theta.min <- 0.001
3 theta.max <- 0.5
4 theta.grid <- seq(theta.min, theta.max, length.out=H)
5 hprior <- dgamma(theta.grid, shape=a, rate=b)
6
7 x.n <- sigma2.n <- lik <- num <- den <- prior <- c()
8 for (h in 1:H) {
9   x.n[h] <- (theta.grid[h]*n*ybar + mu0/sigma2_0) / (theta.grid[h]*n + 1/sigma2_0)
10  sigma2.n[h] <- 1 / (n*theta.grid[h] + 1/sigma2_0)
11  prior[h] <- dnorm(x.n[h], mu0, sd=sqrt(sigma2_0))
12  lik[h] <- prod(dnorm(y, x.n[h], sd=1/sqrt(theta.grid[h])))
13  num[h] <- hprior[h] * prior[h] * lik[h]
14  den[h] <- dnorm(x.n[h], x.n[h], sd=sqrt(sigma2.n[h]))
15 }
16
17 # Distribucion marginal (no normalizada para la precision phi)
18 post.theta <- num/den
19
20 plot(theta.grid, post.theta, xlab=expression(phi), ylab="", pch=20, cex=1.3, ylim=range(post.theta,
21 spline(theta.grid, post.theta)$y))
22 lines(smooth.spline(theta.grid, post.theta, all.knots=T))

```

**Fig. S8.** Distribución de $\phi \mid y$.


El normalizar la distribución de $\phi \mid y$, se determina por

Listing 13. Distribucion a posteriori (normalizada) de la precisión phi.

```

1 f.theta <- approxfun(theta.grid, post.theta, yleft=min(theta.grid), yright=max(theta.grid))
2 const <- integrate(f.theta, min(theta.grid), max(theta.grid))
3 post.theta <- post.theta/const$value
4
5 plot(theta.grid, post.theta, xlab=expression(theta), ylab="", pch=20, cex=1.3, ylim=range(post.
6   theta, spline(theta.grid, post.theta)$y))
7 lines(smooth.spline(theta.grid, post.theta, all.knots=T))

```

**Fig. S9.** Distribución normalizada de $\phi \mid y$.

Observandose aún una cola muy extensa a la derecha de la distribución.

Ahora, lo que se busca es generar la distribución de $\theta \mid \phi, y$ determinada por

$$\theta^{(k+1)} \mid \phi, y \propto p(\theta^{(k)}, 1/\phi^{(k)}) \quad (S10)$$

Luego mediante una sumatoria finita con pesos respectivos para $p(\theta | \phi, y)$, tenemos que

$$p(\theta^{(k+1)} | y) \propto \sum_j p(\theta^k | \phi^{(j)}, y) p(\phi^{(j)} | y) \underbrace{\frac{1}{\sum_j p(\phi^{(j)} | y)}}_{\text{Pesos}} \quad (\text{S11})$$

Listing 14. Distribución para $\theta | \phi, y$.

```

1 J <- 50
2 min.x <- -8
3 max.x <- 5
4 x.grid <- seq(min.x, max.x, length.out=J)
5
6 # Distribucion condicional theta | phi, y
7 full.cond.x <- matrix(NA, J, H)
8 for (j in 1:J) {
9   for (h in 1:H) {
10     full.cond.x[j, h] <- dnorm(x.grid[j], x.n[h], sd=sqrt(sigma2.n[h]))
11   }
12 }
13
14 plot(x.grid, full.cond.x[, 1], t="l", lwd=.7, ylab="", xlab=expression(theta), ylim=range(full.cond.x),
15      cex=1.3)
16 for (h in 1:H) {
17   lines(x.grid, full.cond.x[, h], lwd=.7)
18 }

```




Fig. S10. Distribución para $\theta | \phi, y$.

Listing 15. Distribución conjunta de $\theta, \phi | y$.

```

1 # Insercion de los pesos
2 Delta <- 1/sum(post.theta)
3 joint.post.x.theta <- matrix(NA, J, H)
4 for (h in 1:H) {
5   joint.post.x.theta[, h] <- full.cond.x[, h] * post.theta[h] * Delta
6 }
7
8 # Integracion bajo phi para obtener la distribucion marginal posterior para theta
9 marg.post.x <- rowSums(joint.post.x.theta)
10
11 rg <- c(-0.839603, 5.836238)
12 plot(x.grid, marg.post.x, t="l", xlab=expression(theta), ylab="",
13      xlim=c(rg[1], max(x.grid)), lty=2, lwd=3)
14 for (h in 1:H) {
15   lines(x.grid, joint.post.x.theta[, h], lwd=.5)
16 }

```




Fig. S11. Distribución conjunta de $\theta, \phi \mid \mathbf{y}$.

En Fig S11, visualizamos la distribución de $\theta \mid \mathbf{y}$ como una curva punteada que viene determinada como la suma de las distribuciones a posteriori de $\theta, \phi \mid \mathbf{y}$ multiplicadas por sus pesos respectivos y representadas cada una por las curvas solidas.